

TP 1 : découverte pandas — seaborn

Initiation au Machine Learning

Objectifs

Dans ce TP, vous manipulez un jeu de données réel : des mesures relevées sur des manchots de l'Antarctique (espèce, taille du bec, masse...). Vous allez apprendre à l'explorer, en extraire des sous-ensembles, y faire des calculs statistiques élémentaires et le visualiser. On travaille avec deux bibliothèques Python : **pandas** pour manipuler les données, **seaborn** pour les représenter graphiquement.

Chercher sans IA


Pour pandas. Pour trouver une fonction que vous ne connaissez pas, procédez **dans cet ordre** :

1. complétion `df.` puis Tab : voir la liste des méthodes disponibles ;
2. aide intégrée `df.methode?` : lire la documentation d'une méthode précise ;
3. *cheat sheet* pandas : https://pandas.pydata.org/Pandas_Cheat_Sheet.pdf
(Nous utiliserons principalement la partie *Summarize Data*) ;
4. documentation pandas : <https://pandas.pydata.org/docs>.

Pour seaborn.

- la galerie d'exemples : <https://seaborn.pydata.org/examples/index.html> ;
- la documentation : <https://seaborn.pydata.org>.

Pas d'assistant IA sur ce TP. C'est en cherchant vous-même que vous ancrez les savoir-faire de base.



1 Prise en main

Exercice 1 : Création du notebook

Pour ce premier TP, c'est à vous d'écrire l'intégralité du code. Ouvrez un nouveau notebook (Jupyter) et enregistrez-le sous le nom `TP1_penguins.ipynb`.

Exercice 2 : En utilisant *Summarize Data*

1. Recopiez et exécutez la cellule suivante pour importer les bibliothèques et charger les données dans `df`.

```
import pandas as pd
import seaborn as sns

df = sns.load_dataset("penguins")
```

2. a) Recopiez et exécutez la cellule suivante pour obtenir de l'aide sur la méthode `head` :


```
df.head?
```

b) Affichez les 10 premières lignes de `df` pour voir à quoi ressemblent les données.

D'après cet aperçu, à quoi correspond une ligne du tableau ? 

3.  Cochez les informations qui figurent dans le dataset :

- | | |
|--|---|
| ☐ longueur du bec | ☐ largeur de la nageoire |
| ☐ profondeur du bec | ☐ âge du manchot |
| ☐ envergure des ailes | ☐ île d'observation |
| ☐ couleur du plumage | ☐ sexe |
| ☐ masse corporelle | ☐ date d'observation |
| ☐ longueur de la nageoire | |



Afficher la *cheat sheet* pandas (disponible ici : https://pandas.pydata.org/Pandas_Cheat_Sheet.pdf) et repérer la partie Summarize Data.

4. Combien le dataset contient-il de lignes et de colonnes ?


 Nombre de lignes = Nombre de colonnes =

5. Affichez les statistiques descriptives des colonnes numériques.

 masse moyenne = masse minimale =

6. Affichez les espèces présentes et l'effectif de chacune. (*une méthode donne les deux*)

 Espèce la plus présente : Son effectif :



Exercice 3 :

Reliez chaque fonction à sa description (ex. : 1 → c).

- | | |
|--|--|
| 1. <code>df.head()</code> | a. statistiques des colonnes numériques |
| 2. <code>df.shape</code> | b. compte les occurrences de chaque valeur |
| 3. <code>df.info()</code> | c. affiche les premières lignes |
| 4. <code>df.describe()</code> | d. noms et types des colonnes |
| 5. <code>df["col"].value_counts()</code> | e. nombre de lignes et de colonnes |

Réponses : 1 → 2 → 3 → 4 → 5 →

2 Sélectionner des sous-ensembles

Exercice 4 :

1. **Sélection d'une colonne.** *On accède à une colonne par son nom. Ex :*

```
df["species"]
```

Affichez la colonne des masses corporelles.

2. **Sélection de plusieurs colonnes.** *Il faut alors utiliser une liste de noms entre doubles crochets. Ex :*

```
df[["species", "body_mass_g"]]
```

Affichez simultanément les colonnes `species`, `island` et `sex`.

3. **Filtrage des lignes : avec une condition.** *Pour ne garder que les lignes qui vérifient une condition, on écrit la condition entre crochets. Ex :*

```
df[df["sex"] == "Male"]
```

Affichez uniquement les manchots de l'île de Torgersen.

4. **Filtrage des lignes : avec un seuil numérique.** *La condition peut utiliser les opérateurs de comparaison (`>=`, `>`, `<=`, `<`, `!=`). Ex :*

```
df[df["body_mass_g"] >= 4000]
```

Affichez les manchots dont la longueur de nageoire dépasse strictement 210 mm.

5. **Filtrage des lignes : plusieurs conditions.** *On entoure chaque condition de parenthèses et on les combine avec le opérateur (ET) ou (OU). Ex :*

```
df[(df["species"] == "Adelie") & (df["sex"] == "Male")]
```

Affichez les manchots de l'espèce `Gentoo` pesant plus de 5000 g.

Mémo : Sélectionner des lignes ou des colonnes

- une colonne : `df["col"]`
- plusieurs colonnes : `df[["col1", "col2"]]`
- filtrer (égalité, texte) : `df[df["col"] == "texte"]`
- filtrer (seuil, nombre) : `df[df["col"] >= nombre]`
- filtrer (plusieurs) : `df[(cond1) & (cond2)]`

Exercice 5 : Création d'un sous-tableau.

On souhaite construire un nouveau dataset nommé `df_adelie` extrait de `df`.

Il ne contient **que** les manchots Adélie et **seulement** trois colonnes : `bill_length_mm`, `body_mass_g` et `sex`.

1. Créez `df_adelie` et affichez ses premières lignes.
Indication : vous pouvez procéder en deux étapes
2. Vérifiez votre sélection avec `df_adelie.shape`
La réponse attendue est (152, 3) — 152 manchots Adélie et 3 colonnes.
3. Affichez les statistiques de `df_adelie`.
Quelle est la masse moyenne et la masse minimale des manchots Adélie.

 Masse moyenne = Masse minimale =

Exercice 6 : Calculs statistiques élémentaires

Dans cet exercice on travaille avec `df` le dataset entier. Les méthodes `mean()`, `min()` ou encore `max()` permettent d'obtenir des informations statistiques. Ces résultats peuvent éventuellement être conservés dans une variable. Ex :

```
masse_moyenne = df["body_mass_g"].mean()
```

Remarque : *Certaines mesures sont manquantes dans ce jeu de données (Nan). Les fonctions statistiques (`mean`, ...) les ignorent automatiquement.*

1. Quelle est la plus grande longueur de nageoire observable sur l'île de Dream ?
2. Déterminez le poids moyen des manchots femelles.
3. Déterminez la longueur minimale de bec pour l'espèce Adélie.
4. Déterminez la longueur moyenne des nageoires pour les manchots mâles dont la masse est supérieure à 4000g.
5.  Quelle est la longueur de bec moyenne des manchots mâles de l'île de Dream dont la masse corporelle est supérieure au poids moyen de tous les manchots de l'île de Torgersen ?

3 Premières visualisations avec seaborn**Exercice 7 : Explorer la structure des données avec seaborn****1. Visualiser une variable numérique**

- a) Tracez l'histogramme des masses corporelles de tous les manchots.

```
sns.histplot(data=df, x="body_mass_g", bins = 10)
```

- b) Modifiez la valeur de `bins` (essayez 3, puis 30).

2. Croiser une variable catégorielle et une numérique.

- a) Tracez un *strip plot* de la masse en fonction de l'espèce.

```
sns.stripplot(data=df, x="species", y="body_mass_g")
```

- b) Ajoutez l'option `hue="sex"`.

3. Croiser deux variables numériques.

- a) Tracez le nuage de points suivant :

```
sns.scatterplot(data=df, x="bill_length_mm", y="flipper_length_mm", hue="sex")
```

- b) On observe un nouveau manchot : bec de 45 mm, nageoire de 195 mm. D'après le graphique, est-il facile de décider si c'est un mâle ou une femelle ? 

4. Croiser toutes les variables numériques.

- a) Exécutez la commande suivante

```
sns.pairplot(df, hue="sex")
```

- b) Quel croisement de deux mesures sépare le mieux les sexes ? 

5. Isolons le croisement le plus intéressant.

- a) Tracez le nuage de points (avec `sns.scatterplot`) des deux mesures que vous avez sélectionnées, colorées par sexe :
- b) Sur ce graphique agrandi, pourrait-on tracer **une droite** séparant à peu près les mâles des femelles ? Resterait-il des points du mauvais côté ? 